

0. 적대적 공격 개념

목적 : Input을 사람이 알아보기 거의 불가능할만큼 바꾸면서, 생성한 적대적 샘플(이미지)의 라벨과 분류결과 (output)은 완전히 다른 값이 나오게 하는 것 (Loss maximization)

epsilon : Input과 adversarial sample의 픽셀 차이 제한값

프로젝트 목적

교통 표지판 자율 주행 중요. 적대적 샘플 인식 못하면 사고남. 프로젝트로 적대적 공격의 원리 이해하고, 교통 표지판 데이터셋에 대한 공격기법을 만들어보고, 방어기법을 만들어보자

1. Base Model assessment

Base model : ResNet-18 (or CNN)

Dataset : GTSRB (교통표지판 데이터셋)

- 구현이 너무 무거워지거나 시간이 오래 걸린다면 MNIST, CIFAR도 고려

2. Adversarial attack example generation

1) White-box / untargeted

공격자가 모델을 다 아는 최악에 가까운 상황에서 얼마나 버티는가를 확인하기 위해 white-box / Untargeted method를 사용한다.

2) methods

FGSM : NN의 입력 x 에 대한 loss gradient를 1번 사용해서(loss 증가 방향으로 x 변화) 이미지에 노이즈 (perturbation)을 넣는 기법 (빠르고 단순)

PGD : FGSM 반복

C&W : 최적화 기반 공격

custom method : Edge aware attack

- 직관 : 표지판의 분류는 edge기반일 것임 -> edge에 perturbation을 주자

3) To Do

original dataset에 각각의 공격방법을 적용하여 dataset-FGSM, dataset-PGD ... 을 만든다

3. Model Robustness assessment

Base Model의 각 데이터셋에서의 성능을 평가한다

평가지표

1) Clean acc : 원본 데이터셋에서의 정확도

2) Adv acc : 각 적대적 데이터셋에 대한 분류 정확도

3) Attack success rate : original에서는 맞췄으나, 적대적 데이터셋에서는 틀리는 데이터의 비율 (각 적대적 데이터셋 별)

4) Perturbation cost : 원본 이미지에서 바뀐 정도

4. Defense method

기존의 Baseline model이 적대적 샘플에서도 잘 작동할 수 있도록 모델에 변화를 준다

0) baseline model

1) preprocessing : Gaussian blur, Median filter JPEG etc

2) Adversarial training : NN학습시 각 배치마다 FGSM/PGD 적용해 adversarial batch 생성하고, 현재의 모델에 대해 adv batch의 loss를 토대로 그라디언트를 업데이트해 robust한 NN을 만드는 방식

3) custom method

- morphological operator based denoising
- FFT 기반 denoising (주파수 영역에서 제거)

Auto attack algorithm 적용해서 각 base 모델 및 방어모델 성능 최종 평가